

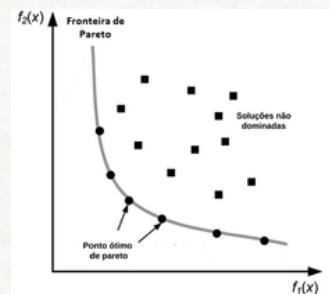
Ele foi desenvolvido para lidar com problemas que possuem múltiplos objetivos a serem otimizados simultaneamente.

INTRODUÇÃO

- O MOEA/D分解 um problema de otimização multiobjetivo em N subproblemas de otimização escalar;
- Esses subproblemas são otimizados simultaneamente a partir da evolução de uma população de soluções;
- Em cada geração, a população é composta pelas melhores soluções encontradas para cada subproblema;
- Cada subproblema é otimizado considerando apenas informações de subproblemas vizinhos;

Procura encontrar a Fronteira de Pareto, que é o conjunto de soluções que não podem ser melhoradas em um objetivo sem piorar em outro

Solução Pareto-ótima: Uma solução é considerada Pareto-ótima quando não pode ser melhorada em relação a um objetivo sem piorar em pelo menos um outro objetivo.



FLUXO DE EXECUÇÃO

Inicialização da População: Criação de uma população inicial de soluções candidatas. Essas soluções podem ser geradas aleatoriamente ou usando alguma heurística específica, dependendo do problema em questão.

Avaliação da Aptidão (Fitness) das Soluções: Cada solução da população é avaliada em relação aos múltiplos objetivos do problema. A aptidão de uma solução é calculada usando as funções de decomposição, que medem o desempenho da solução em relação aos subproblemas escalares.

Decomposição do Problema: O problema multiobjetivo é decomposto em N subproblemas escalares independentes. Cada subproblema é otimizado separadamente, tratando apenas um único objetivo, o que simplifica o processo de busca.

Geração de Novas Soluções (Reprodução): O MOEA/D usa operadores genéticos, como crossover (cruzamento) e mutação, para gerar novas soluções com base nas soluções existentes da população. Essas novas soluções são adicionadas à população atual.

Atualização da População: Uma vez que novas soluções foram geradas, a população é atualizada. O MOEA/D utiliza um critério de seleção para determinar quais soluções serão mantidas na próxima geração, buscando equilibrar a diversidade e convergência das soluções.

Critérios de Parada: O algoritmo repete os passos de avaliação, decomposição, geração de novas soluções e atualização da população em um número predeterminado de iterações ou até que um critério de parada seja alcançado. O critério de parada pode ser baseado em um número máximo de iterações, convergência das soluções ou outras medidas de decomposição.

DECOMPOSIÇÃO PONDERADA

- Técnica utilizada para abordar problemas de otimização multiobjetivo por meio da decomposição do problema global em subproblemas mais fáceis de serem tratados.
- Cada subproblema visa otimizar um único objetivo. Portanto, estes serão otimizados individualmente.
- São utilizadas **funções de decomposição** para atribuir pesos aos diferentes objetivos de cada subproblema.

- Com a decomposição e a definição das funções de decomposição, o MOEA/D lida com os subproblemas de forma simultânea e gera um conjunto de soluções candidatas após sua resolução.

- A otimização de um subproblema utiliza as informações atuais de seus subproblemas vizinhos, uma vez que dois subproblemas vizinhos devem possuir soluções ótimas próximas.

Soma Ponderada

$$\text{maximize } g^{ws}(x|\lambda) = \sum_{i=1}^m \lambda_i f_i(x)$$

subject to $x \in \Omega$

MOEA-D

Multi-Objective Evolutionary Algorithm based on Decomposition

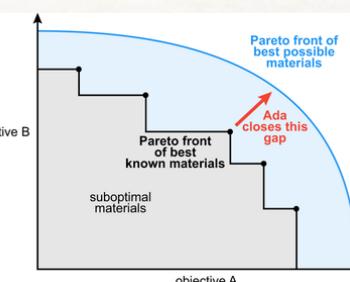
CURIOSIDADES

Como o objetivo é alcançar a Fronteira de Pareto (FP), a melhor distribuição de soluções provavelmente vai ser uniforme, de qualquer forma, não é fácil fazer isso.

MAS quando o método de decomposição e os vetores de peso são adequadamente escolhidos, e assim as soluções ótimas para os subproblemas resultantes são distribuídas uniformemente ao longo da PF, o MOEA/D terá uma boa chance de produzir uma distribuição uniforme de soluções de Pareto se ele otimizar todos esses subproblemas muito bem.

Devido ao fato do subproblema ser otimizado usando apenas informações de seus subproblemas vizinhos, faz com que o MOEA-D tenha uma complexidade computacional menor em cada geração do que o NSGA-II

Os resultados experimentais mostraram que o MOEA-D com métodos simples de decomposição supera ou tem um desempenho semelhante ao NSGA-II em problemas de mochila binária multiobjetivo e problemas de otimização multiobjetivo contínuos



Abordagem de Tchebycheff

$$\text{minimize } g^{te}(x|\lambda, z^*) = \max_{1 \leq i \leq m} \{\lambda_i |f_i(x) - z_i^*|\}$$

subject to $x \in \Omega$

Abordagem da Penalidade Baseada em Intersecção de Fronteira

$$\text{minimize } g^{bip}(x|\lambda, z^*) = d_1 + \theta d_2$$

subject to $x \in \Omega$

$$d_1 = \frac{\|(z^* - F(x))^T \lambda\|}{\|\lambda\|}$$

$$\text{and } d_2 = \|F(x) - (z^* - d_1 \lambda)\|.$$